สถิติเบื้องต้นด้วย R

เปลี่ยนข้อมูลให้เป็นข้อสรุปผ่านการทดสอบสมมติฐานและสมการเชิงเส้น

NotebookLM

Descriptive and Inferential statistics

Descriptive statistics

Sample selection

Population

Sample

Sample size

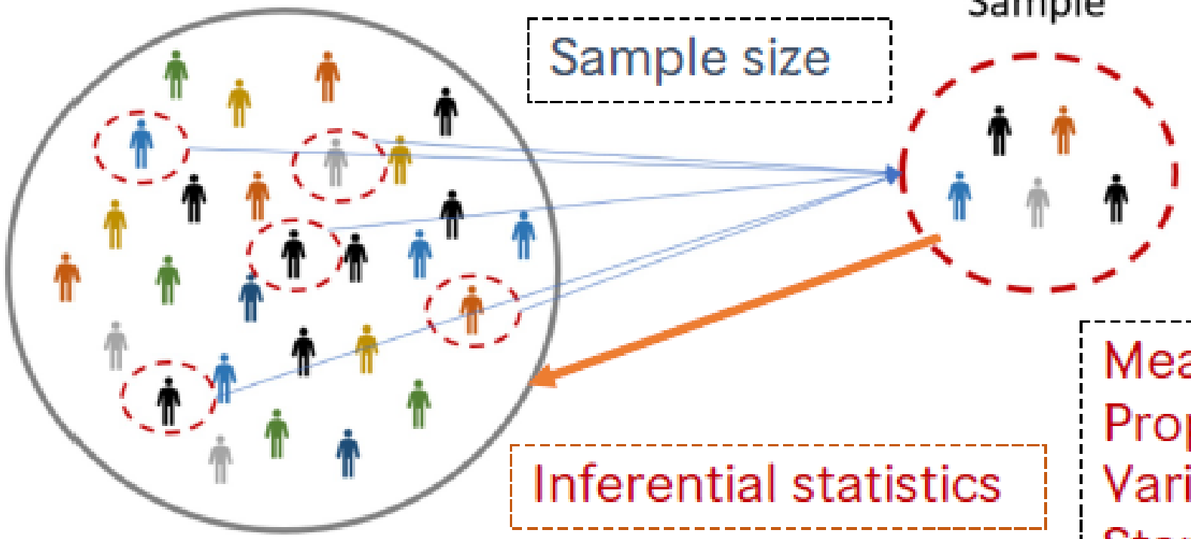

Parameters

Statistics

Mean ($\bar{x}$)
Proportion (p)
Variance (s^2)
Standard deviation (sd)

Inferential statistics

- Estimation
- Hypothesis testing

Mean (μ)
Proportion (π)
Variance (σ^2)
Standard deviation (σ)

Null hypothesis (H_o) VS Alternative hypothesis (H_a)

- The *null hypothesis* (H_0) is usually the prediction that there is **no relationship** in the population or **no difference** between groups.
  - » $H_0 : \mu_1 = \mu_2$

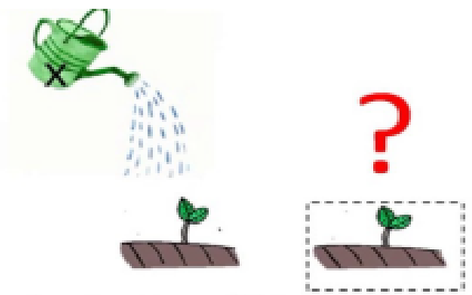

H_0: Application of bio-fertilizer 'x' do not increase plant growth.

- The *alternative hypothesis* (H_1 or H_a) is the logical opposite of the null hypothesis and says there is a **relationship** in the population or the groups are **different**.
  - » $H_1 : \mu_1 \neq \mu_2$ / $H_1 : \mu_1 < \mu_2$ / $H_1 : \mu_1 > \mu_2$

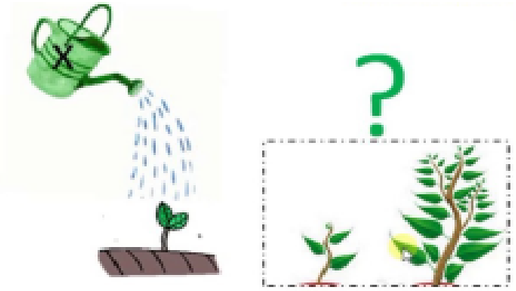

H_1: Application of bio-fertilizer 'x' increase plant growth.

https://www.quora.com/How-do-you-create-a-null-hypothesis-in-statistics

SIMPLE INFERENTIAL STATISTICS

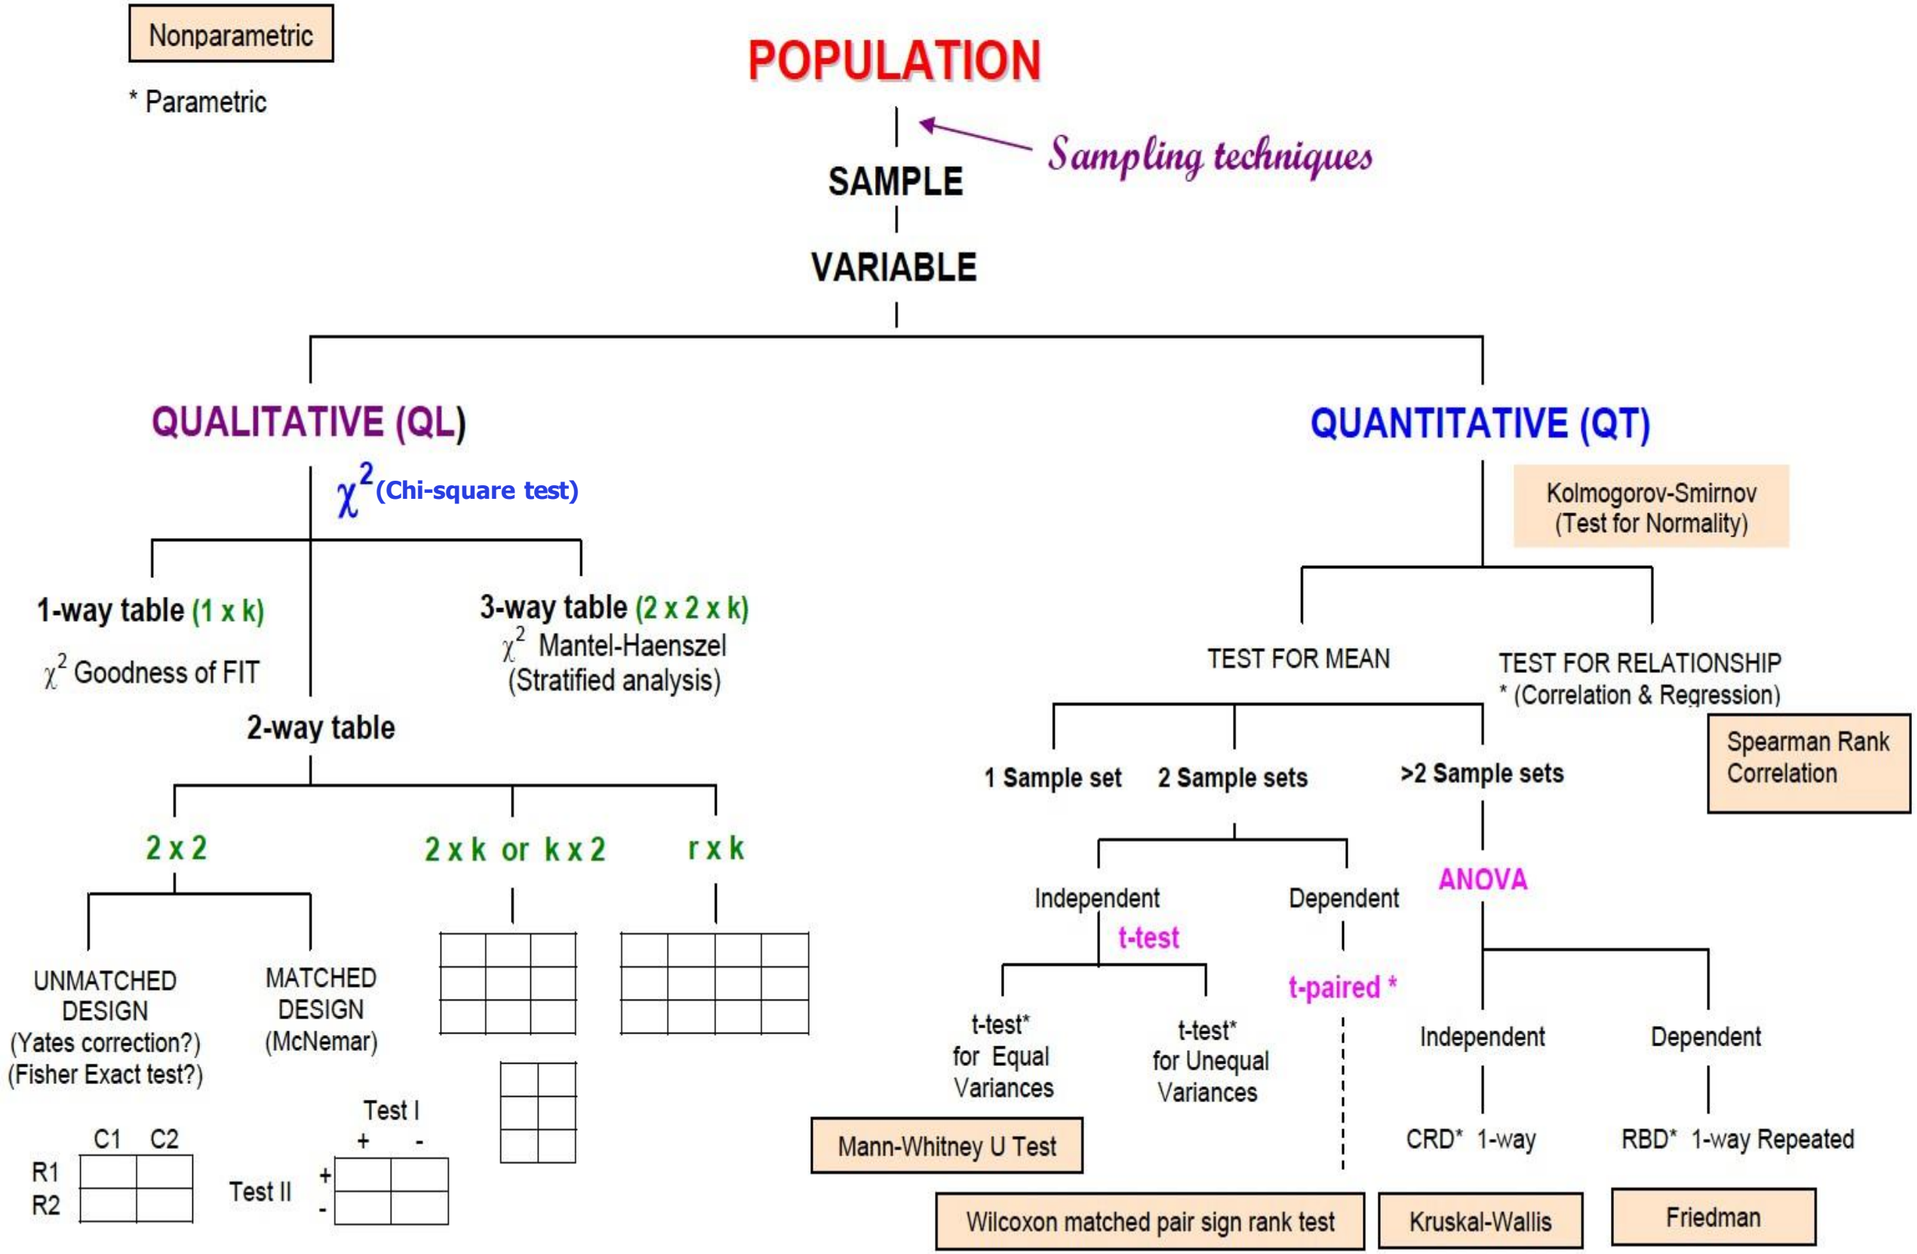

การตรวจสอบการแจกแจงปกติ (Normality Checks)

ตรวจสอบด้วยกราฟ (Q-Q Plot)

```
qqnorm(trees$Height)
qqline(trees$Height, lty = 2)
```

ลากเส้นอ้างอิง (เส้นประ) เพื่อดูว่าจุดข้อมูลเกาะกลุ่มตามแนวเส้นทแยงมุมหรือไม่

ตรวจสอบด้วยสถิติ (Shapiro-Wilk)

```
shapiro.test(trees$Height)

W = 0.96545, p-value = 0.4034
```

p-value > 0.05 หมายถึงไม่มีหลักฐานปฏิเสธสมมติฐานหลัก (ยอมรับว่าข้อมูลมีการแจกแจงแบบปกติ)

NotebookLM

การทดสอบสมมติฐานค่าเฉลี่ย (One-Sample T-Test)

เปรียบเทียบค่าเฉลี่ยของกลุ่มตัวอย่างกับค่าเป้าหมายที่กำหนด
(เช่น ความสูงต้นไม้เฉลี่ยเท่ากับ 70 หรือไม่?)

```
t.test(trees$Height, mu = 70)
```

```
t = 5.2429
p-value = 1.173e-05
mean of x 76
```

(ค่าสถิติ t)

(ค่านัยสำคัญทางสถิติ)

(ค่าเฉลี่ยที่คำนวณได้จากกลุ่มตัวอย่าง)

p-value < 0.05 สรุปได้ว่าค่าเฉลี่ยความสูง ไม่เท่ากับ 70 อย่างมีนัยสำคัญ

NotebookLM

การกำหนดทิศทางของการทดสอบ (Directional Hypothesis)

R อนุญาตให้เราตั้งสมมติฐานแบบเจาะจงทิศทางได้ผ่านอาร์กิวเมนต์ alternative

Greater

```
t.test(trees$Height, mu = 70,
       alternative = "greater")
```

ทดสอบว่าค่าเฉลี่ย "มากกว่า" 70 หรือไม่

Less

```
t.test(trees$Height, mu = 70,
       alternative = "less")
```

ทดสอบว่าค่าเฉลี่ย "น้อยกว่า" 70 หรือไม่

NotebookLM

ความสัมพันธ์ของตัวแปร (Correlation)

แค่คำนวณค่า (Value Only)

```
cor(trees$Height, trees$Volume)
```

```
[1] 0.5982497
```

ฟังก์ชัน **cor()** ให้แค่ค่าสัมประสิทธิ์สหสัมพันธ์ (r) แต่ไม่บอกว่ามีนัยสำคัญหรือไม่

ทดสอบนัยสำคัญ (Statistical Significance)

```
cor.test(trees$Height, trees$Volume)
```

```
   Pearson's product-moment correlation

data: trees$Height and trees$Volume
t = 3.9894, df = 29, p-value = 0.0003784
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
  0.3032734 0.7859096
sample estimates:
      cor
0.5982497
```

ฟังก์ชัน **cor.test()** ทำการทดสอบทางสถิติเพื่อยืนยันว่าความสัมพันธ์นั้นแตกต่างจาก 0 จริงๆ

NotebookLM

การสร้างสมการเชิงเส้น (Simple Linear Model)

หากต้องการใช้ตัวแปรหนึ่งเพื่อ "ทำนาย" อีกตัวแปรหนึ่ง เราจะใช้ฟังก์ชัน **lm()** (Linear Model)

```
y ~ x
```

y (ตัวแปรตาม/Dependent)

~ (อธิบายด้วย)

x (ตัวแปรอิสระ/Independent)

```
lm_df <- lm(weight ~ height, data = data6)
```

สร้างโมเดลทำนายน้ำหนัก (weight) โดยอิงจากส่วนสูง (height) และเก็บไว้ในออบเจกต์ lm_df

NotebookLM

การอ่านผลลัพธ์โมเดล (Interpreting the Model)

```
summary(lm_df)
(Intercept)  -85.91950
height         0.90941
p-value:  < 2.2e-16
Multiple R-squared:  0.3027
```

Coefficients: ส่วนสูงเพิ่ม 1 หน่วย น้ำหนักเพิ่ม 0.909 หน่วย

Significance: ค่า p-value < 0.05 แสดงว่าส่วนสูงมีผลต่อน้ำหนักจริง

R-squared: โมเดลนี้อธิบายความแปรปรวนของน้ำหนักได้ 30.27%

NotebookLM

การวาดกราฟเส้นแนวโน้ม (Visualizing the Model)

นำสมการเชิงเส้นที่ได้มาแสดงผลเป็นภาพเพื่อให้เข้าใจง่ายขึ้นด้วยการเติมเลเยอร์ geom_smooth()

```
ggplot(mapping = aes(x = height, y = weight),
       data = data6) +
  geom_point() +
  geom_smooth(method = "lm", se = TRUE)
```

- "method = "lm": บังคับให้เส้นแนวโน้มเป็นเส้นตรง (Linear Model)
- "se = TRUE": แสดงแถบความคลาดเคลื่อนมาตรฐาน (Standard Error) สีเทา

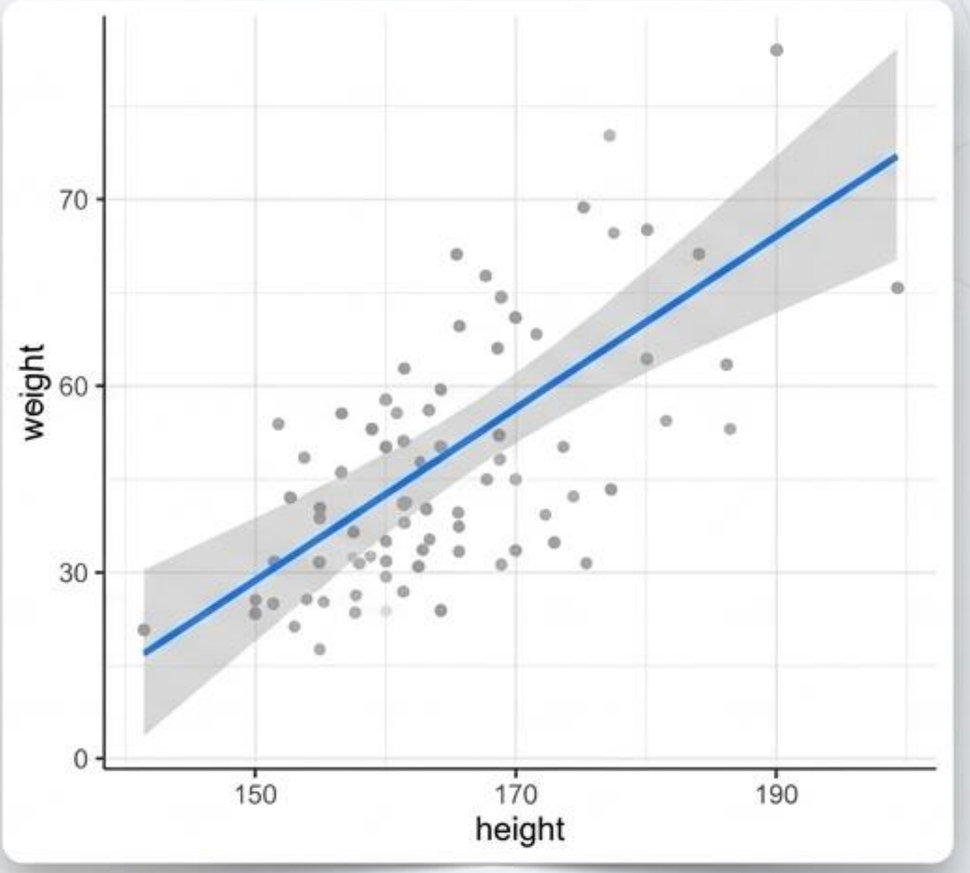

NotebookLM

สรุปฟังก์ชันสถิติเบื้องต้น (Summary Cheat Sheet)

`shapiro.test(x)`
ทดสอบการแจกแจงปกติ (Normality)

`t.test(x, mu = 0)`
ทดสอบสมมติฐานค่าเฉลี่ย (T-Test)

`cor(x, y)`
คำนวณค่าสัมประสิทธิ์สหสัมพันธ์ (Correlation Value)

`cor.test(x, y)`
ทดสอบนัยสำคัญของความสัมพันธ์ (Correlation Significance)

`lm(y ~ x)`
สร้างสมการเชิงเส้น (Linear Model)

`summary(model)`
ดูรายละเอียดและผลลัพธ์ของโมเดลทั้งหมด

NotebookLM